

Génération de Modèles de Taux d'Intérêt par Ponts de Schrödinger : Approches par Noyau et LSTM

Lizhan Hong

École Polytechnique

Projet Scientifique Collectif (PSC)

Décembre 2025

Résumé

Ce rapport présente une étude approfondie de l'application des Ponts de Schrödinger (SB) [1] pour la génération de séries temporelles financières, spécifiquement dans le contexte des courbes de taux d'intérêt modélisées par des processus de retour à la moyenne (Ornstein-Uhlenbeck). Nous implémentons et comparons deux méthodes d'estimation du terme de dérive (drift) : l'estimateur de Nadaraya-Watson (Kernel) et une approche par réseau de neurones récurrents (LSTM) [2]. Nos expériences mettent en évidence les défis critiques liés à l'échelle des données et à l'effondrement de la variance, et démontrent la supériorité de l'approche neuronale pour capturer la dynamique globale et la structure de corrélation du processus cible.

1 Introduction et Cadre Théorique

La génération de scénarios économiques réalistes est un enjeu majeur pour la gestion des risques (Calcul de PFE, EEPE) au sein des institutions financières comme la Société Générale. Les méthodes traditionnelles (Monte Carlo standard) peinent parfois à capturer les dépendances temporelles complexes. Récemment, Hamdouche et al. [1] ont proposé une approche générative basée sur les Ponts de Schrödinger (SB).

1.1 Formulation du Problème

Le problème consiste à trouver une mesure de probabilité $\mathbb{P}^*$ sur l'espace des trajectoires qui est la plus proche (au sens de la divergence de Kullback-Leibler) d'une mesure de référence $\mathbb{W}$ (Mouvement Brownien), tout en satisfaisant les contraintes marginales imposées par les données historiques μ .

La solution optimale est caractérisée par une équation différentielle stochastique (EDS) sur un horizon fini $[0, T]$:

$$dX_t = a^*(t, X_t)dt + dW_t \quad (1)$$

où $a^*(t, X_t)$ est le terme de dérive optimal (optimal drift), qui est en général dépendant de la trajectoire (path-dependent).

1.2 Estimation du Drift

Le cœur de l'algorithme réside dans l'estimation de ce drift a^* . D'après [1], pour un processus de Markov, ce terme peut être approximé par une espérance conditionnelle sous la mesure cible :

$$a^*(t, x) \approx \frac{\mathbb{E}_\mu[(X_{t_{i+1}} - x) \cdot K_h(X_{t_i} - x)]}{\Delta t \cdot \mathbb{E}_\mu[K_h(X_{t_i} - x)]} \quad (2)$$

où K_h est un noyau (Kernel) de largeur de bande h . Cette formulation permet d'apprendre la dynamique directement à partir des données, sans résoudre d'EDP complexe.

2 Implémentation et Logique du Code

Notre implémentation se concentre sur la simulation d'un processus d'Ornstein-Uhlenbeck (OU), représentatif de la dynamique des taux d'intérêt :

$$dX_t = \theta(\mu_{LT} - X_t)dt + \sigma dW_t \quad (3)$$

avec une volatilité faible ($\sigma \approx 0.02$) et une forte réversion à la moyenne.

2.1 Pré-traitement : Normalisation Critique

Une étape cruciale, souvent omise dans la théorie mais vitale en pratique, est la **standardisation des données**. Les taux d'intérêt évoluant à des échelles très faibles (~ 0.05), le bruit du mouvement brownien de référence ($\sigma_{ref} = 1$) domine le signal. Nous appliquons une transformation $Z = \frac{X - \mu_X}{\sigma_X}$ avant l'entraînement, et la transformation inverse après la génération.

2.2 Approche A : Estimation par Noyau (Kernel)

Nous avons implémenté l'estimateur de Nadaraya-Watson avec un noyau Gaussien.

— **Vectorisation** : Le calcul des distances par paires entre les particules générées et les données historiques est entièrement vectorisé via `NumPy` pour l'efficacité.

- **Stabilité** : Un terme de régularisation ϵ et un seuil minimal pour Δt sont ajoutés pour éviter les singularités numériques lorsque $t \rightarrow t_{i+1}$.

2.3 Approche B : Estimation par LSTM

Pour pallier les limites locales du noyau, nous avons implémenté un réseau LSTM (Long Short-Term Memory) sous PyTorch.

- **Architecture** : LSTM (hidden size=32) suivi d'une couche linéaire.
- **Entraînement** : Le réseau apprend à prédire X_{t+1} sachant X_t (et potentiellement l'historique) en minimisant la MSE.
- **Drift** : Le drift est dérivé par la différence finie : $\hat{a}(t, x) = \frac{\text{LSTM}(x) - x}{\Delta t}$.

3 Expérimentation et Analyse

Notre recherche a suivi un processus itératif de diagnostic et d'amélioration, illustré par les comparaisons graphiques.

3.1 Phase 1 : Le Problème d'Échelle (Scale Mismatch)

Lors des premiers essais avec les données brutes, les trajectoires générées s'apparentaient à un bruit blanc (White Noise). L'autocorrélation était nulle. **Analyse** : La volatilité intrinsèque du modèle SB (basée sur le mouvement brownien standard) écrasait la structure fine des données de taux. Cela a motivé l'introduction du **StandardScaler**.

3.2 Phase 2 : L'Effondrement de la Variance (Approche Noyau)

Après normalisation, l'approche par noyau a réussi à capturer la tendance de retour à la moyenne. Cependant, nous avons observé un phénomène de "Variance Collapse".

- **Observation** : La distribution marginale générée présentait un pic excessif (leptokurtique) et les trajectoires étaient trop lisses.
- **Explication** : L'estimateur par noyau effectue une moyenne locale. Avec une largeur de bande h trop grande ou des données éparées, il converge vers l'espérance conditionnelle $\mathbb{E}[X_{t+1}|X_t]$, supprimant la composante stochastique nécessaire pour reproduire la "rugosité" des marchés.

3.3 Phase 3 : Supériorité du LSTM

L'introduction du modèle LSTM a permis de résoudre ces limitations.




FIGURE 1 – Comparaison des générateurs. Le LSTM (Bleu) reproduit fidèlement la volatilité et l'autocorrélation des données historiques (Noir), contrairement au Kernel (Rouge) qui sous-estime la variance.

Comme illustré dans la Figure 1 :

1. **Trajectoires** : Le LSTM génère des chemins qui explorent mieux l'espace d'états, évitant la concentration excessive autour de la moyenne.
2. **Dynamique** : La structure d'autocorrélation (Lag-1) du LSTM se superpose parfaitement à celle des données historiques, validant la capture du paramètre de "Mean Reversion".
3. **Robustesse** : Contrairement au noyau qui est sensible au choix de l'hyperparamètre h , le LSTM apprend une fonction globale, moins sujette au sur-lissage local.

4 Conclusion et Perspectives

Ce travail confirme que les Ponts de Schrödinger constituent un cadre puissant pour la modélisation des taux d'intérêt. Bien que l'approche théorique par noyau soit élégante, son application pratique souffre de problèmes d'échelle et de lissage. L'approche neuronale (LSTM), suggérée par Hamdouche et al., s'avère bien plus robuste pour capturer la volatilité stochastique réelle.

Pour le stage à venir, il serait pertinent d'étendre cette approche aux dimensions élevées (courbe de taux complète) où les méthodes à noyau échouent (fléau de la dimension), et d'intégrer des contraintes économiques explicites (taux positifs) dans la fonction de perte du réseau neuronal.

Références

- [1] E. Schrödinger. *Über die Umkehrung der Naturgesetze*. Sitzungsberichte der Preussischen Akademie der Wissenschaften, 1931.
- [2] M. Hamdouche, P. Henry-Labordère, and H. Pham. *Generative modeling for time series via Schrödinger bridge*. arXiv preprint arXiv :2304.05093, 2023.